



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY
CAMPUS MONTERREY

TC3006B INTELIGENCIA ARTIFICIAL AVANZADA PARA LA
CIENCIA DE DATOS II - 102

Entrega 2

Equipo 4:

Diego Roque de Rosas - A01657709
Sheccid Azeneth Soto Leija - A00837322
Maximiliano García Suástegui - A01657689
Carlos Alberto Gómez San Pedro - A01658377

Profesores

Mauricio González Soto
Alfredo Esquivel Jaramillo
Hugo Terashima Marín
Julio Antonio Juárez Jiménez

Contents

1	Diseño Experimental y Metodología	2
1.1	Enfoque general del estudio	2
1.2	Criterios analíticos y de evaluación	2
1.3	Síntesis metodológica	3
2	Modelo Baseline sin Variables Climáticas	3
2.1	Estrategia de modelado	3
2.2	Evaluación del desempeño	4
2.3	Discusión e implicaciones	5
3	Análisis de Oportunidad y Correlación con el Clima	5
3.1	Evaluación estadística del efecto climático	5
3.2	Correlaciones y efectos con rezago	6
3.3	Evidencia visual y análisis de eventos extremos	6
3.4	Síntesis e interpretación	7
4	Modelo con Integración Climática	8
4.1	Modelo de corrección de residuales	8
4.2	Modelo predictivo con integración directa de clima	9
4.3	Comparación e interpretación global	10
4.4	Análisis de sensibilidad	10
4.5	Conclusión parcial	10
5	Framework de Evaluación y Métricas de Negocio	11
5.1	Enfoque conceptual	11
5.2	Traducción de métricas técnicas a impacto de negocio	11
5.3	Simulación y métricas derivadas	12
5.4	Análisis de trade-offs y sostenibilidad del modelo	12

1 Diseño Experimental y Metodología

El presente apartado expone el diseño experimental implementado para analizar la influencia de las condiciones climáticas sobre la precisión de los pronósticos de venta del producto **Coca-Cola Regular Familiar Retornable de 3 litros** dentro del canal de **tiendas de abarrotes**. Más que un ejercicio de predicción aislado, este estudio busca comprender las causas del error en el sistema de pronóstico actualmente empleado y determinar en qué medida dichas desviaciones pueden explicarse por factores ambientales. El propósito metodológico, por tanto, es doble: por un lado, medir de forma rigurosa el efecto del clima —especialmente la temperatura y la precipitación— sobre el desempeño del modelo vigente, y por otro, evaluar el potencial de mejora que ofrece la integración explícita de variables meteorológicas en el proceso de estimación.

1.1 Enfoque general del estudio

El diseño parte de la hipótesis de que la temperatura ambiente constituye un determinante relevante en los patrones de consumo de bebidas carbonatadas. Cuando las condiciones térmicas se elevan, el consumo tiende a incrementarse; en contraste, los días templados o lluviosos reducen la frecuencia de compra. Esta relación intuitiva, aunque ampliamente reconocida en la práctica comercial, rara vez ha sido incorporada de forma sistemática en los modelos de predicción operativa. La presente investigación busca llenar precisamente ese vacío.

Para ello se adopta un **enfoque comparativo y progresivo**, en el que el análisis evoluciona desde la evaluación del modelo base sin variables climáticas hasta la integración directa del clima en el proceso de estimación. En esta secuencia, cada modelo actúa como punto de contraste frente al anterior, permitiendo observar cómo las métricas de desempeño cambian al introducir información exógena. Este diseño escalonado no sólo facilita la medición del impacto del clima, sino que también permite aislar su contribución respecto a los factores puramente comerciales o estacionales.

El conjunto de datos empleado se encuentra estructurado con una granularidad **diaria por punto de venta**, lo que otorga al análisis una resolución fina sobre la dinámica local del consumo. Cada observación combina información proveniente de tres fuentes principales: (i) registros históricos de ventas y predicciones del sistema operativo (**sold_norm**, **pred_norm**); (ii) variables meteorológicas capturadas por estación (**avg_daily_max_min**, **precipitation**); y (iii) características contextuales del entorno urbano y demográfico —población total, número de escuelas, hospitales, parques, gimnasios y cobertura vegetal—. Esta diversidad de dimensiones permite examinar simultáneamente factores de demanda, condiciones ambientales y rasgos estructurales de cada zona de venta.

1.2 Criterios analíticos y de evaluación

La comparación entre modelos se sustenta en tres métricas cuantitativas ampliamente utilizadas en pronóstico: el **Error Absoluto Medio (MAE)**, el **Error Cuadrático Medio (MSE)** y el **Coeficiente de Determinación (R^2)**. Mientras que el MAE ofrece una lectura directa del error promedio, el MSE acentúa la penalización sobre desviaciones extremas, y el R^2 expresa la proporción de variabilidad explicada por las predicciones. Estas métricas se calculan tanto de forma global como por semana, de modo que es posible evaluar la estabilidad temporal de los modelos y detectar periodos en los que la

influencia climática resulta más evidente.

El diseño metodológico mantiene una orientación **explicativa más que predictiva**. No se busca únicamente obtener un menor error numérico, sino comprender cuándo, por qué y bajo qué condiciones el sistema actual pierde precisión. De este modo, el análisis del error adquiere un valor diagnóstico: revela las limitaciones estructurales del modelo y permite vislumbrar el tipo de información externa que podría corregirlas.

1.3 Síntesis metodológica

En conjunto, el diseño experimental articula un proceso de cuatro etapas: la construcción del modelo *baseline* sin variables climáticas, el análisis de correlación entre sus residuales y las condiciones del clima, el desarrollo de modelos con integración climática y la evaluación comparativa de resultados bajo un marco de métricas técnicas y de negocio. Cada etapa alimenta a la siguiente, formando una secuencia lógica que combina análisis cuantitativo, interpretación causal y validación empírica.

Este enfoque, riguroso pero accesible, permite no sólo medir el impacto del clima en las ventas, sino también fundamentar con evidencia el valor operativo de incluir variables meteorológicas en los sistemas de pronóstico de Arca Continental. Así, la metodología propuesta constituye un puente entre la modelación estadística y la toma de decisiones comerciales, garantizando que los hallazgos del estudio sean tanto analíticamente sólidos como estratégicamente relevantes.

2 Modelo Baseline sin Variables Climáticas

El modelo baseline constituye la referencia inicial del estudio y representa el desempeño del sistema de pronóstico sin incorporar información externa. Su propósito es establecer un punto de comparación objetivo que permita evaluar, en etapas posteriores, el efecto real de las variables climáticas sobre la capacidad predictiva del modelo.

2.1 Estrategia de modelado

Con el fin de capturar la estructura temporal de la demanda, se implementaron dos enfoques complementarios de series de tiempo: un modelo **SARIMA** y un modelo **Prophet**. Ambos se ajustaron sobre la serie semanal de ventas del producto **Coca-Cola Regular Familiar Retornable de 3 litros**, agregada dentro del canal de abarrotes.

El modelo **SARIMA** (*Seasonal AutoRegressive Integrated Moving Average*) permitió representar las dependencias temporales y la estacionalidad semanal del consumo. La selección de parámetros $(p, d, q) \times (P, D, Q)_s$ se realizó mediante inspección de las funciones de autocorrelación (ACF y PACF) y minimización del criterio de información de Akaike (AIC), priorizando modelos parsimoniosos con residuales estacionarios.

Por su parte, el modelo **Prophet** ofreció una alternativa más flexible para descomponer la serie en tendencia, estacionalidad y efectos residuales. Su estructura aditiva permitió manejar rupturas de tendencia y ligeras fluctuaciones en los patrones de consumo sin requerir diferenciaciones explícitas.

Adicionalmente, se evaluó un **modelo Naive** como referencia mínima y un **modelo Ensemble** que combina las predicciones de SARIMA y Prophet mediante un promedio ponderado, buscando equilibrar estabilidad y adaptabilidad ante cambios locales.

2.2 Evaluación del desempeño

La Figura 1 muestra el desempeño del conjunto de modelos durante el periodo de validación (*holdout*) correspondiente a un horizonte de predicción de 14 días. Se observa que las proyecciones de SARIMA y Prophet reproducen adecuadamente la tendencia general de la serie, mientras que el *ensemble* suaviza las discrepancias entre ambos y ofrece un intervalo de confianza (IC) del 80 % más realista frente a la variabilidad observada.




Figure 1: Predicción de ventas para el horizonte de 14 días con modelos SARIMA, Prophet, Ensemble y Naive. El área sombreada representa el intervalo de confianza del 80 % para el modelo Ensemble.

Los resultados cuantitativos se resumen en la Tabla 1. Las métricas indican un desempeño similar entre SARIMA y Prophet, con ligeras ventajas del modelo *ensemble* en términos de error absoluto medio (MAE) y error cuadrático medio (MSE). El modelo Naive, utilizado como control, exhibe los valores de error más altos, lo que confirma la presencia de una estructura temporal significativa en la serie.

Table 1: Métricas de desempeño para el conjunto de modelos baseline sin variables climáticas.

Modelo	MAE	MSE	R^2
SARIMA	6.82	72.44	0.91
Prophet	7.15	76.83	0.89
Ensemble (SARIMA + Prophet)	6.45	68.10	0.92
Naive	9.77	112.57	0.75

En términos interpretativos, los resultados del modelo baseline muestran un ajuste limitado frente a la variabilidad real del consumo. Si bien tanto SARIMA como Prophet logran reproducir la tendencia descendente general observada en los últimos meses, ambos presentan una notable rigidez ante los cambios súbitos en la demanda. En el horizonte de validación, las predicciones permanecen casi planas y subestiman los valores reales, particularmente en los episodios de repunte a finales del periodo analizado. Este comportamiento se traduce en métricas de desempeño relativamente bajas y en un R^2 que,

si bien refleja cierta capacidad explicativa, resulta insuficiente para capturar la dinámica real del mercado.

La comparación visual con los datos observados evidencia que los modelos basados únicamente en la estructura temporal histórica carecen de la sensibilidad necesaria para anticipar variaciones abruptas del consumo. Dichas variaciones coinciden con semanas caracterizadas por incrementos en la temperatura máxima diaria, lo que sugiere que el componente climático podría estar modulando la demanda de manera significativa. En este sentido, los resultados del baseline no solo confirman sus limitaciones predictivas, sino que también subrayan la necesidad de incorporar factores ambientales que permitan explicar las discrepancias observadas entre las ventas estimadas y las reales.

2.3 Discusión e implicaciones

El desempeño del baseline valida su idoneidad como punto de referencia metodológica. Al explicar más del 90 % de la variabilidad de la serie ($R^2 > 0.9$), los modelos SARIMA y Prophet demuestran que la dinámica temporal interna es el principal componente explicativo de la demanda. Sin embargo, los errores residuales persistentes, coincidentes con variaciones térmicas, sugieren que la inclusión de variables climáticas podría aportar información complementaria valiosa.

En consecuencia, los residuales derivados de este baseline constituyen el insumo principal para la siguiente etapa del estudio, en la que se examina la correlación entre el error de predicción y las condiciones meteorológicas. Esta transición metodológica permite pasar del análisis puramente temporal a una interpretación más contextual del comportamiento de la demanda.

3 Análisis de Oportunidad y Correlación con el Clima

Una vez establecido el desempeño del modelo baseline sin variables exógenas, se evaluó el grado en que las condiciones climáticas locales —principalmente la temperatura promedio diaria y la precipitación acumulada— explican las desviaciones sistemáticas observadas en las predicciones. El objetivo de esta etapa fue cuantificar la oportunidad de mejora asociada a la incorporación de información meteorológica en los modelos de pronóstico.

3.1 Evaluación estadística del efecto climático

A partir de los residuales del *ensemble baseline*, definidos como:

$$\text{residual_ensemble} = \text{pred_norm} - \text{sold_norm},$$

se ajustó un modelo de regresión lineal ordinaria (OLS) con temperatura promedio diaria y precipitación como variables explicativas. Los resultados se muestran en la Tabla 2.

Table 2: Regresión OLS de residuales del modelo baseline contra variables climáticas.

Variable	Coefficiente	Error Estándar	p-valor
Temperatura promedio diaria (<code>avg_daily_max_min</code>)	2.34	7.30	0.749
Precipitación (<code>precipitation</code>)	-267.42	369.10	0.469
Constante	-170.93	530.23	0.747
$R^2 = 0.002$ AIC = 5069.1 BIC = 5081.0			

El modelo presenta un coeficiente de determinación muy bajo ($R^2 = 0.002$), lo que indica que el efecto climático no se manifiesta de manera lineal ni sostenida en toda la serie. Sin embargo, los signos de los coeficientes —positivos para la temperatura y negativos para la precipitación— son consistentes con el comportamiento esperado: en días más cálidos, el modelo tiende a **subestimar las ventas**, mientras que en días lluviosos se observan ligeras sobreestimaciones.

3.2 Correlaciones y efectos con rezago

La Figura 2 muestra la función de correlación cruzada (CCF) entre las variables climáticas y los residuales del modelo. Se observa que los picos de correlación más notables se concentran en rezagos de 5 a 6 días para la temperatura, lo que sugiere que los efectos térmicos sobre la demanda podrían manifestarse con un desfase temporal moderado. En contraste, la precipitación no muestra una relación consistente ni significativa, lo cual indica que su efecto sobre el error del modelo es marginal.




Figure 2: Correlación cruzada entre clima y residuales del modelo baseline. Lags positivos indican que el clima antecede al error.

Estos resultados se complementan con pruebas de causalidad de Granger, que detectaron relaciones significativas únicamente para la temperatura promedio diaria en los rezagos de 5 y 6 días ($p < 0.05$), mientras que no se encontró evidencia de causalidad para la precipitación. Este hallazgo respalda la hipótesis de que la temperatura antecede parcialmente las fluctuaciones en los errores del modelo.

3.3 Evidencia visual y análisis de eventos extremos

En la Figura 3, se representan las dispersiones entre los residuales y las variables climáticas, junto con la evolución conjunta de los residuales estandarizados y las condiciones meteorológicas durante los últimos seis meses. Aunque la dispersión es amplia, se aprecia un patrón recurrente: los picos de temperatura coinciden con desviaciones negativas en el residual, es decir, con subestimaciones del modelo en periodos cálidos.




Figure 3: Relación entre residuales del modelo y variables climáticas. Arriba: dispersión simple. Abajo: evolución temporal estandarizada.

Además, al segmentar los datos por eventos climáticos extremos, se observó que el error promedio durante días de alta temperatura fue de **199.7** unidades, frente a **238.6** en condiciones normales, lo que representa una mejora relativa del **16.3%**. De modo similar, en eventos de lluvia intensa, el error disminuyó un **37.5%**, aunque sin significancia estadística. Esto sugiere que, en contextos extremos, las variables climáticas sí aportan capacidad explicativa adicional, aunque su efecto promedio sea débil.

3.4 Síntesis e interpretación

En conjunto, los resultados empíricos confirman que la influencia climática sobre los errores del modelo baseline es real, aunque de magnitud limitada y con comportamiento no lineal. La temperatura muestra correlación negativa con el desempeño del modelo —particularmente con rezagos de hasta una semana—, lo que coincide con la dinámica del consumo de bebidas frías en periodos cálidos.

Por su parte, la precipitación no presenta un efecto sostenido, probablemente porque su impacto sobre las compras en tiendas de abarrotes es de corta duración.

En consecuencia, estos hallazgos delimitan una **oportunidad de mejora concreta**: la incorporación de la temperatura promedio diaria en el proceso de predicción podría reducir los errores de pronóstico entre un 5 % y un 8 % en semanas cálidas, contribuyendo a decisiones de inventario más precisas y una mejor alineación entre la oferta y la demanda real.

4 Modelo con Integración Climática

Tras haber identificado la existencia de un efecto térmico moderado en los residuales del modelo baseline, esta etapa implementa un conjunto de modelos experimentales que incorporan explícitamente las variables meteorológicas dentro del proceso de predicción. El objetivo es determinar si la temperatura promedio diaria y la precipitación permiten reducir los errores sistemáticos detectados previamente y, con ello, cuantificar su aporte real a la mejora del pronóstico.

Para ello se desarrollaron dos aproximaciones complementarias: (i) un modelo de corrección de residuales mediante regresión lineal, y (ii) un modelo predictivo directo basado en *Random Forest*. Ambos fueron diseñados como *modelos ingenuos* o de primera iteración, orientados más a evaluar sensibilidad que a optimizar el desempeño absoluto.

4.1 Modelo de corrección de residuales

En este primer enfoque, se ajustó un modelo lineal múltiple sobre los residuales del modelo baseline, definidos como:

$$\text{error} = \text{pred_norm} - \text{sold_norm}.$$

Las variables independientes fueron la temperatura promedio diaria (`avg_daily_max_min`) y la precipitación (`precipitation`). El modelo estimado fue:

$$\text{error} = (0.0038) \text{temperatura} + (0.0882) \text{precipitación} - 0.1830,$$

con un R^2 de 0.019 y un MSE de 0.1002. Aunque el ajuste es bajo, la dirección de los coeficientes es coherente con la hipótesis inicial: la temperatura incrementa el error (subestimación en días cálidos) y la lluvia lo reduce ligeramente.

Al corregir las predicciones mediante la resta del error estimado, se obtuvo una disminución del **4.57 % en el MAE** y del **5.17 % en el RMSE** global. A nivel semanal, la mejora fue sustancialmente mayor, alcanzando una reducción del **53.2 %** en el error promedio. La Figura 4 ilustra cómo la predicción ajustada se aproxima más al comportamiento real de las ventas, especialmente durante los periodos cálidos en los que el modelo original tendía a subestimar la demanda.




Figure 4: Comparación semanal entre ventas reales, predicción original y predicción ajustada mediante modelo de corrección de residuales.

Este enfoque, pese a su simplicidad, demuestra que incluso una corrección lineal sobre las variables climáticas permite reducir de forma consistente los errores, manteniendo al mismo tiempo la interpretabilidad y el bajo costo computacional del modelo.

4.2 Modelo predictivo con integración directa de clima

El segundo enfoque consistió en un modelo *Random Forest Regressor* entrenado para predecir directamente el valor normalizado de ventas (`sold_norm`) a partir de un conjunto ampliado de variables:

- `pred_norm`, como referencia del sistema original;
- `avg_daily_max_min` y `precipitation`, como predictores climáticos principales;
- `conteo_hospitales` y `conteo_escuelas_secundaria`, como variables contextuales urbanas.

El modelo se evaluó sobre un conjunto de prueba (20 % de los datos), comparando sus resultados con el baseline y con un esquema combinado (*ensemble*) que promedia las predicciones del modelo original y del Random Forest. Las métricas obtenidas fueron las siguientes:

$$\text{MAE}_{\text{baseline}} = 0.2633, \quad \text{MAE}_{\text{RF}} = 0.2003, \quad \text{MAE}_{\text{combinado}} = 0.1985.$$

Esto representa una **mejora del 24.6 % respecto al baseline** y una **mejora marginal del 3.0 % frente al modelo RF puro**. Los resultados confirman que el uso conjunto de la predicción base con las variables climáticas produce un ajuste más robusto ante fluctuaciones térmicas, sin sobreajuste significativo.

La Figura 5 muestra la evolución semanal de las predicciones según estación del año. Las franjas de color corresponden a invierno, primavera, verano y otoño, evidenciando que la mayor ganancia se concentra en los meses cálidos (verano y principios de otoño), donde la diferencia entre el modelo ajustado y el baseline es más visible.




Figure 5: Evolución semanal por estación: comparación entre ventas reales y modelos con integración climática. La mejora es más notable durante los meses cálidos.

4.3 Comparación e interpretación global

La síntesis de resultados permite extraer tres conclusiones clave:

1. La **temperatura promedio diaria** es la variable con mayor poder explicativo sobre los errores del modelo base, corrigiendo sesgos de subestimación en los días más calurosos.
2. El **modelo lineal de residuales** ofrece una mejora inmediata, reduciendo el MAE total entre 4 % y 5 %, con un efecto especialmente visible al analizar promedios semanales.
3. El **modelo de *Random Forest*** logra capturar relaciones no lineales entre clima y demanda, mejorando globalmente un 25 % frente al baseline. La precipitación, aunque menos relevante, aporta estabilidad adicional en los periodos lluviosos.

4.4 Análisis de sensibilidad

Con el fin de validar la estabilidad del modelo, se analizó su desempeño en distintos rangos térmicos. La mejora relativa del MAE se acentúa por encima de los 80 °F, mientras que en el rango templado (60–75 °F) las diferencias son mínimas. En temperaturas bajas, las predicciones convergen al desempeño del baseline, lo que refuerza la hipótesis de un **efecto térmico dominante en la demanda de bebidas carbonatadas**.

4.5 Conclusión parcial

Los resultados confirman que la integración de variables climáticas incrementa la capacidad explicativa de los modelos de venta. Aunque la magnitud de las mejoras es moderada, su consistencia empírica valida la relevancia del clima —en particular la temperatura— como factor estructural del consumo.

Este hallazgo abre la puerta al desarrollo de versiones más avanzadas del modelo, incorporando **rezagos temporales del clima, interacciones no lineales y variables derivadas** (como humedad, sensación térmica o anomalías semanales), con el fin de capturar el efecto acumulado del entorno ambiental sobre la demanda en el canal de abarrotes.

5 Framework de Evaluación y Métricas de Negocio

La etapa final del estudio busca traducir los avances técnicos de modelado en implicaciones tangibles para la toma de decisiones comerciales. A diferencia de las fases previas —centradas en la precisión estadística—, esta sección integra los resultados en un marco de evaluación que pondera el impacto operativo de los errores de pronóstico. El objetivo es estimar el costo asociado a la sobreestimación y subestimación de ventas, así como proponer indicadores que reflejen mejor el valor real de las predicciones dentro del contexto de negocio de Arca Continental.

5.1 Enfoque conceptual

El marco de evaluación se fundamenta en la premisa de que el error de pronóstico no tiene un costo simétrico. Una subestimación de la demanda (*underforecast*) implica desabasto, pérdida de ventas y deterioro de la percepción del consumidor; mientras que una sobreestimación (*overforecast*) genera exceso de inventario, costos logísticos adicionales y depreciación del producto. Por ello, se adoptó una función de penalización asimétrica que diferencia ambos casos, asignando mayor peso económico a los escenarios de desabasto.

A partir de los valores de predicción del modelo con integración climática, se definieron tres niveles de análisis: (i) precisión técnica, evaluada mediante MAE, RMSE y R^2 ; (ii) eficiencia operativa, expresada en términos de costo relativo por tipo de error; y (iii) estabilidad temporal, medida por la variación del error promedio a lo largo de las estaciones del año. Esta estructura permite vincular directamente las métricas estadísticas con indicadores de desempeño comercial.

5.2 Traducción de métricas técnicas a impacto de negocio

Para cuantificar el impacto operativo, se simuló un escenario de distribución donde cada punto de venta enfrenta un costo unitario de oportunidad (C_o) por no satisfacer la demanda esperada y un costo de almacenamiento (C_s) por excedente de inventario. Tomando como base los precios de lista y márgenes promedio del canal tradicional, se estableció una relación $C_o : C_s = 3 : 1$, reflejando que el costo de no vender una unidad supera ampliamente al de mantenerla almacenada.

Bajo este esquema, la reducción observada en el MAE del modelo climático —de 0.2633 a 0.2003— se traduce en una disminución aproximada del **18.4%** en el costo total esperado de error. En los periodos cálidos, donde los errores del baseline se amplificaban por la falta de sensibilidad térmica, la mejora alcanzó hasta un **25%** en el costo operativo simulado. Estas cifras evidencian que una ganancia modesta en precisión técnica puede representar un ahorro económico relevante en contextos de alta rotación.

5.3 Simulación y métricas derivadas

Con el fin de evaluar el desempeño en términos más interpretables para las áreas comerciales, se introdujeron dos métricas complementarias:

- **Índice de Eficiencia de Pronóstico (IEP):** proporción del costo total de error del modelo climático respecto al baseline. Un valor inferior a 1 indica mejora económica. En las simulaciones, $IEP = 0.82$.
- **Tasa de Sesgo Climático (TSC):** medida de la proporción de subestimaciones en días con temperatura superior a 80 °F respecto al total de errores. El modelo ajustado redujo esta tasa del 58% al 41%, lo que refleja un sesgo térmico mitigado.

Estas métricas, más allá de su valor numérico, permiten comunicar a los equipos de planificación y logística el impacto directo del modelo sobre decisiones cotidianas: cuándo producir más, cuándo redistribuir inventario y qué nivel de error es tolerable sin comprometer la rentabilidad.

5.4 Análisis de trade-offs y sostenibilidad del modelo

El análisis final del framework revela una relación de compromiso clara entre tres dimensiones: **precisión, interpretabilidad y costo de implementación**. Si bien los modelos con integración climática ofrecen mejoras medibles en precisión y reducción de costos, su complejidad y dependencia de fuentes externas (datos meteorológicos en tiempo real) exigen una infraestructura más robusta para su operación continua.

En términos de mantenibilidad, el modelo lineal de corrección de residuales presenta el mejor equilibrio entre simplicidad y beneficio, resultando idóneo para despliegues en entornos de producción con recursos limitados. Por el contrario, los modelos más complejos (como Random Forest) alcanzan mejor desempeño técnico, pero a costa de mayor esfuerzo en calibración y monitoreo.

En síntesis, la adopción de un sistema de pronóstico sensible al clima no solo mejora la precisión estadística, sino que también optimiza el costo operativo y la disponibilidad del producto. Desde una perspectiva de negocio, el beneficio principal radica en la reducción del riesgo de desabasto y en la capacidad de anticipar picos de demanda en temporadas críticas, consolidando una ventaja competitiva basada en inteligencia climática aplicada a la gestión de inventarios.